TP : MODELOS LINEALES GENERALIZADOS

Bioestadística

Ing. Agr. Juan Manuel Solís
Cátedra de Bioestadística y Diseño Experimental. Lic. en Ciencias Biológicas. Facultad de Ciencias Agrarias. Universidad Nacional de Jujuy.
juanmasolis@fca.unju.edu.ar

Año 2026



Contenidos

- Regresión logística para datos binomiales agrupados
- Regresión de *Poisson* para datos de conteos

GLM

$$\eta = \beta_0 + \beta_1 x_i$$

$$\eta = g(\mu)$$

Donde $g(\mu)$ es la **función de enlace**. Luego,

$$\mu = g^{-1}(\eta)$$

Cuando $g(\mu)$ es el enlace *canónico*, corresponde al parámetro θ.

Principales miembros de la familia exponencial en la forma canónica

Distribución	$f(y)$	Rango	θ	$b(\theta)$	ϕ	$a(\phi)$
Normal	$\frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{(y-\mu)^2}{2\sigma^2}}$	$-\infty < y < \infty$	μ	$\frac{\theta^2}{2}$	σ^2	ϕ
Poisson	$\frac{e^{-\mu}\mu^y}{y!}$	$y = 0, 1, 2, \ldots$	$\log(\mu)$	$\exp(\theta)$	1	ϕ
Binomial (escalada)	$\binom{m}{my}p^{my}(1-p)^{m-my}$	$y = 0, \frac{1}{m}, \frac{2}{m}, \ldots, 1$	$\log\left(\frac{p}{1-p}\right)$	$\log(1+\exp(\theta))$	1	$\frac{\phi}{m}$
Gamma	$\frac{1}{\Gamma(\nu)}\left(\frac{\nu}{\mu}\right)^{\nu}y^{\nu-1}\exp\left(-\frac{\nu y}{\mu}\right)$	$y > 0$	$-\frac{1}{\mu}$	$-\log(-\theta)$	$\frac{1}{\nu}$	ϕ
Normal inversa	$\sqrt{\frac{1}{2\pi\sigma^2y^3}}e^{-\frac{(y-\mu)^2}{2\mu^2\sigma^2y}}$	$y > 0$	$-\frac{1}{2\mu^2}$	$-\sqrt{-2\theta}$	σ^2	ϕ

Regresión logística para datos binomiales agrupados

Experimento binomial

- Se realizan *n* ensayos independientes.
- Cada ensayo produce uno de dos resultados posibles: éxito (1) o fracaso (0).
- La probabilidad de éxito es constante de un ensayo a otro y se denota con p.

La variable aleatoria *R* que cuenta el número de éxitos en los **n** ensayos independientes tiene distribución binomial con parámetros *n* y *p* ($R \sim B(n, p)$).

Si denotamos con Y a la variable aleatoria que mide la proporción de éxitos en los n ensayos independientes (número de éxitos dividido el total n, Y=R/n), la distribución de Y está dada por:

$$P(Y = y) = \binom{n}{ny} p^{ny}(1-p)^{n-ny}$$

- $\mu = \mathsf{E}(Y) = p$
- $Var(Y) = \frac{p(1-p)}{n}$
- $Var(\mu) = \mu(1-\mu)$

Situación 1

Se realizó un estudio para caracterizar la morfología de líquenes en diferentes sustratos (corteza de árboles: 0, rocas:1) observados en distintos sitios de la provincia de Jujuy. Se caracterizó a los talos según su forma en *costrosos* y *otros*. A fin de simplificar el análisis, se clasificó a los sitios en *tierras altas: 1* (por encima de los 2500 msnm) y *tierras bajas: 0*. A continuación se muestran los recuentos para cada tipo de líquen.

sitio	sustr	costr	otros
0	1	50	30
0	0	88	75
1	1	5	9
1	0	20	46

```r
costr=c(50,88,5,20)
otros=c(30,75,9,46)
sustrato=c(1,0,1,0)
sitio=c(0,0,1,1)
modelo=glm(cbind(costr,otros)~sitio+sustrato,family=binomial)
```

```r
summary(modelo)
```

```
##
## Call:
## glm(formula = cbind(costr, otros) ~ sitio + sustrato, family = binomial)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)   0.1656     0.1529   1.083 0.278792
## sitio        -1.0151     0.2762  -3.675 0.000238 ***
## sustrato      0.3330     0.2541   1.310 0.190048
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 17.747717  on 3  degrees of freedom
## Residual deviance:  0.024415  on 1  degrees of freedom
## AIC: 23.87
##
## Number of Fisher Scoring iterations: 3
```

```r
predict(modelo,type = "response")
```

```
##         1         2         3         4
## 0.6221110 0.5412952 0.3736514 0.2995285
```

```r
exp(coef(modelo))
```

```
## (Intercept)       sitio    sustrato
##   1.1800514   0.3623654   1.3950917
```

Regresión de *Poisson* para datos de conteos

Distribución de *Poisson*

Se utiliza para conteos de eventos que ocurren aleatoriamente en un periodo de tiempo o en un determinado espacio (y por extension a cualquier intervalo de continuidad)

Si $Y \sim P(\lambda)$, entonces la función de distribución de *Y* está dada por:

$$P(Y = y) = \frac{e^{-\lambda}\lambda^{y}}{y!}, y = 0, 1, 2, ...$$

Con $E(Y) = Var(Y) = Var(\lambda) = \lambda$

Situación 2

Un ingeniero obtuvo los siguientes datos acerca de la cantidad de fallas de un cierto componente. Hay tres configuraciones de diseño distintas para el componente y cuatro modos de falla posibles.

	Modo de falla			
Configuración	1	2	3	4
1	20	44	17	9
2	4	17	7	12
3	10	31	14	8

```
conteo=c(20,44,17,9,4,17,7,12,10,31,14,8)
config=gl(3,4)
falla=gl(4,1,12)
modelo=glm(conteo~config+falla,family=poisson)
```

```r
summary(modelo)
```

```
##
## Call:
## glm(formula = conteo ~ config + falla, family = poisson)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)   2.7635     0.1880  14.700  < 2e-16 ***
## config2      -0.8109     0.1900  -4.267 1.98e-05 ***
## config3      -0.3567     0.1643  -2.171   0.0299 *
## falla2        0.9954     0.2007   4.960 7.06e-07 ***
## falla3        0.1112     0.2361   0.471   0.6375
## falla4       -0.1591     0.2528  -0.629   0.5292
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##     Null deviance: 76.917  on 11  degrees of freedom
## Residual deviance:  9.867  on  6  degrees of freedom
## AIC: 75.022
##
## Number of Fisher Scoring iterations: 4
```

```r
1-pchisq(9.867,6)
```

```
## [1] 0.1303658
```

```r
pred=predict(modelo,type = "response")
cbind(config,falla,conteo,pred)
```

```
##    config falla conteo      pred
## 1       1     1     20 15.854922
## 2       1     2     44 42.901554
## 3       1     3     17 17.720207
## 4       1     4      9 13.523316
## 5       2     1      4  7.046632
## 6       2     2     17 19.067358
## 7       2     3      7  7.875648
## 8       2     4     12  6.010363
## 9       3     1     10 11.098446
## 10      3     2     31 30.031088
## 11      3     3     14 12.404145
## 12      3     4      8  9.466321
```

Bibliografía

- Manual de InfoStat.
- Agresti. Introducción al análisis de datos categóricos.

https://mregresion.files.wordpress.com/2012/08/agresti-introduction-to-categorical-data.pdf

“La estadística es la primera de las ciencias inexactas.” (Edmond Gouncourt)