Trabajo Final de Bioestadística

Facultad de Ciencias Agrarias | Universidad Nacional de Jujuy | Año 2026

Tabla de contenidos

Pautas generales 1
Escenario 1: Perfil de expresión génica en sarcomas (GSE2553) 5
    Introducción y contexto 5
    Importación de datos 5
Escenario 2: Selección del método adecuado de análisis (Producciones de Epistemología) 8
Escenario 3: Parcelas de inventario forestal 9

Pautas generales

Por favor *lean detenidamente las siguientes pautas de trabajo y de presentación* antes de comenzar con su resolución.

Insistimos, por favor *lean detenidamente las siguientes pautas de trabajo y de presentación* antes de comenzar con su resolución.

- Este trabajo final integra los contenidos desarrollados durante el curso. **No** es un segundo parcial.
- Los objetivos de evaluación pueden ser consultados en la Guía de Clases Prácticas (interactiva y documento en pdf). No obstante, vamos a sintetizar estos objetivos en 3 criterios principales: a) **competencia procedimental**: poder ejecutar correctamente el codigo en función del método de análisis que se desea aplicar y obtener los resultados correctos; b) Poder demostrar **criterio** tanto en la selección de métodos como en la interpretación de los resultados, de forma argumentada; c) **Reproducibilidad:** sus análisis deben ser perfectamente reproducibles, lo que permita su *comparabilidad*. Este último objetivo es central para nuestra materia.
- Las preguntas guía de cada escenario no constituyen un cuestionario a responder de manera puntual y sucesiva, sino una hoja de ruta para orientar el análisis. Se valorará especialmente argumentaciones que denoten alguna posición personal con respecto a la situación que deben analizar. La resolución de cada escenario debe adoptar la forma de una redacción argumentativa, en el que los distintos elementos solicitados se integren en una síntesis coherente y no en una lista de respuestas. Se espera que:

    a. Articulen las decisiones metodológicas con las preguntas de investigación, de modo que cada prueba estadística aparezca justificada en función del objetivo que persigue y no como un procedimiento aislado.

b. Hilen los resultados descriptivos, las estimaciones, las pruebas de hipótesis y su interpretación biológica en un continuo, donde cada paso se desprenda del anterior.

c. Den cuenta de los supuestos, las limitaciones y las fuentes de variabilidad no controlada en el mismo cuerpo del texto, integrándolos a la discusión y no como un apéndice separado.

d. Sustenten las conclusiones sobre la evidencia obtenida, explicitando el alcance y los límites de las inferencias realizadas.

e. Se valorará especialmente la capacidad de integrar los contenidos del curso en una argumentación propia. Lo principal es que el texto funcione como una unidad argumental y no como afirmaciones aisladas.

- Los análisis solicitados se limitan a las técnicas vistas en clase. **No deben limitarse a los métodos vistos durante el segundo cuatrimestre**. Deben acompañar sus análisis con elementos de vistos durante la primera parte de la cursada, especialmente estadística descriptiva.
- Los análisis solicitados se limitan también al código visto en clase, cuyos resultados han sido verificados mediante cálculo manual. En caso de incluir funciones o librerías no vistas en clase, deberá justificar su empleo, indicando qué aporte, innovación o mejora realizada con respecto al código visto en clase.
- Durante la defensa oral se le pedirá que justifique o argumente los resultados obtenidos.

Formato de presentación

El trabajo se presentará en un documento pdf sobrio y prolijo, con tipografía serif (Times New Roman o equivalente) de 12 pt, interlineado mínimo márgenes de 2,5 cm, texto justificado y numeración de páginas, sin recursos decorativos, de modo que la atención se dirija al contenido analítico y no al diseño. Cada escenario se organizará como un *símil* artículo científico breve, con una muy breve **introducción** (identificando la pregunta de investigación y los objetivos), **metodología** con justificación de los métodos y verificación de supuestos, **resultados** con tablas y figuras numeradas y tituladas (título arriba en las tablas y debajo en las figuras, sin líneas verticales ni efectos); acompañar las tablas y gráficos con una breve lectura o interpretación previa a la discusión; una breve **discusión** que integre interpretación, limitaciones y fuentes de variabilidad no controlada, y **conclusiones** sintéticas, informando los estadísticos con dos decimales y con notación adecuada. **Se insiste en que el desarrollo debe ser sintético, y no debe exceder las 2 (dos) carillas por escenario. Nota:** En el escenario relacionado con las producciones de Epistemología no deben incluir resultados, discusión ni conclusiones.

Al final de trabajo se incluirá un Anexo, denominado Anexo A, Anexo B y Anexo C (uno para cada escenario) donde incluirán el código R utilizado comentado (usando #). Al ejecutar el código compartido se debe verificar cada valor informado en el texto, es decir, el trabajo debe ser perfectamente **reproducible**, lo cual a los fines de nuestra materia, como se dijo anteriormente, es un objetivo **central**. Pueden usar IA (por ejemplo sus cuadernos de notebooklm de gemini) para escribir código y revisar redacción. No pueden usarla para decidir qué prueba aplicar ni para interpretar los resultados. Deben declarar en el anexo el uso de la IA, por ejemplo prompts, criterios, etc. Recuerden, en la defensa oral se les pedirá que expliquen sus decisiones analíticas.

Piensen en ello como un ejercicio sobre las nuevas formas que se están adoptando para evaluar la reproducibilidad y el uso transparente y honesto de la IA en la investigación. Si el informe escrito es muy preciso y detalladamente explicado, pero en la defensa oral no se evidencia esa claridad metodológica, se asumirá que se ha recurrido al uso de la IA en forma no responsable, debiendo repetir la defensa durante el período de recuperaciones.

Podrán realizar el trabajo final en grupos de hasta 3 (tres) personas. Cada grupo puede adoptar la modalidad de trabajo de su preferencia: algunos grupos pueden preferir distribuirse los escenarios entre sus miembros y luego hacer una compilación y presentación consensuada. Otros pueden preferir resolver todos los escenarios en forma conjunta. Ambas organizaciones son aceptadas. Lo que no será admitida es la presentación de un documento donde quede evidenciada una falta de integración entre las partes. Independientemente de cómo se organicen internamente, el documento final debe leerse como una unidad coherente, y cada integrante debe poder dar cuenta del conjunto del trabajo en la defensa oral, no solo de la parte que resolvió.

Por ese motivo no les pedimos que realicen una presentación en forma de powerpoint o similares, sino argumentar sobre sus producciones.

En el documento indicar la siguiente información acerca de los miembros del grupo de trabajo:

1. Apellido y nombre: _____ **DNI:** _____ **Comisión:** _____

2. Apellido y nombre: _____ **DNI:** _____ **Comisión:** _____

3. Apellido y nombre: _____ **DNI:** _____ **Comisión:** _____

Antes de comenzar, tómense un tiempo para pensar

No se apresuren a ejecutar procedimientos estadísticos apenas comiencen a leer las consignas. Lean detenidamente todas las situaciones planteadas, identifiquen qué se pregunta en cada una, qué variables intervienen y qué tipo de análisis permitiría responder a cada problema. Eso les permitirá crear un "mapa mental" ordenado de lo que deben hacer. La lectura (y relectura) paciente de las consignas podría tomar hasta 40 minutos (una hora en el peor de los casos). Si lo piensan, no es demasiado. Incluso, podrían destinar un momento solo para leer el trabajo final, y luego organizarse para resolverlo en otro momento.

La organización también tiene que ver con otras materias o actividades de su cotidianeidad que deban atender. Nuestra disciplina "funciona mejor" cuando le dedicamos "su propio tiempo", cuando es 'exclusivo'. Si logran organizarse bien, una jornada de trabajo es más que suficiente para resolver la actividad completa. **En estadística, un análisis apurado es un camino seguro hacia la invalidez. Recuerden que primero evaluamos la validez del método, y luego su interpretación.**

Además de organizarse, dediquen unos minutos a establecer un criterio de resolución y justificar las decisiones metodológicas antes de pasar a la ejecución. Propongan alternativas (plan "b", plan "c"). **Escribanlo en un papel**. Usualmente, elegir un procedimiento por ensayo y error no es efectivo. Un tip: pídanle a sus cuadernos de gemini notebooklm que les cree un mapa conceptual acerca de los métodos vistos durante la cursada, incluyendo los problemas que resuelve, supuestos y condiciones de aplicación. Sobre ese mapa, realicen una selección preliminar de los métodos que podrían serles útiles.

Recueden: Primero comprendan el problema, después decidan y finalmente analicen. La calidad del análisis tiene mucho que ver con el criterio y la validez de las decisiones que los orientan.

Escenario 1: Perfil de expresión génica en sarcomas (GSE2553)

Introducción y contexto

En este primer escenario se trabajará con datos de expresión génica provenientes de un estudio sobre sarcomas humanos (*NHGRI_Sarcoma_Baird*), registrado en la base pública GEO (*Gene Expression Omnibus*) con el acceso **GSE2553**.

Resumen del estudio original (metadata):

> Sarcomas are a biologically complex group of tumors of mesenchymal origin. By using gene expression microarray analysis, we aimed to find clues into the cellular differentiation and oncogenic pathways active in these tumors as well as potential biomarkers and therapeutic targets. We examined 181 tumors representing 16 classes of human bone and soft tissue sarcomas on a 12,601-feature cDNA microarray. Remarkably, 2,766 probes differentially expressed across this sample set clearly delineated the various tumor classes. Several genes of potential biological and therapeutic interest were associated with each sarcoma type, including specific tyrosine kinases, transcription factors, and homeobox genes. We also identified subgroups of tumors within the liposarcomas, leiomyosarcomas, and malignant fibrous histiocytomas. We found significant gene ontology correlates for each tumor group and identified similarity to normal tissues by Gene Set Enrichment Analysis. Mutation analysis done on 275 tumor samples revealed that the high expression of epidermal growth factor receptor (EGFR) in certain tumors was not associated with gene mutations. Finally, to further the investigation of human sarcoma biology, we have created an online, publicly available, searchable database housing the data from the gene expression profiles of these tumors (http://watson.nhgri.nih.gov/sarcoma), allowing the user to interactively explore this data set in depth.

Palabras clave: sarcoma, cDNA, tumor profiling.

Importación de datos

Para iniciar el trabajo, importe el conjunto de datos GSE2553, incluido en el objeto `ds`. El objeto `ds` contiene, entre otros elementos, dos tablas con 181 filas cada una (una fila por muestra tumoral):

- `ds$samples`: información descriptiva y técnica de las muestras (12 variables).
- `ds$enriched`: información armonizada de tejido, tipo celular y enfermedad (36 variables). Nosotros trabajaremos con este set de datos.

Ejecute el siguiente código en su entorno de R:

```
load(file.choose()) # Deberá seleccionar el archivo 'ds.RData', que es un formato
de almacenamiento de datos comprimido de R.

# Tabla enriched: una fila por muestra: tejido, tipo celular y enfermedad
```

```
armonizados
ds$enriched
```

El primer paso será construir la tabla `datos`, con las siguientes características:

```
# 1. Seleccionar solo las columnas que nos importan (creando un data.frame nuevo)
datos         =         ds$enriched[,         c("cell_type",         "disease",
"treatment","development_stage")]

# 2. Limpiar los textos (pasar todo a minúsculas y factores)
datos$cell_type = as.factor(tolower(datos$cell_type))
datos$disease   = as.factor(tolower(datos$disease))
datos$treatment = as.factor(tolower(datos$treatment))
datos$development_stage = as.factor(tolower(datos$development_stage))


# 3. Realizar una selección con reposición lo que permitirá que cada grupo tenga
datos diferentes.

semilla = 1234 # Nota: cada grupo debe MODIFICAR el número de semilla (no
utilizar 1234)
set.seed(semilla)
library(dplyr) # previamente se debe instalar
datos  = datos |>
   group_by(cell_type) |>                    # estrato: tipo celular
   slice_sample(prop = 1, replace = TRUE) |>   # Selección dentro de cada estrato
   ungroup()

# Explorar
summary(datos)
table(datos$cell_type)
```

> ! Importante
>
> Cada grupo trabajará con una versión diferente pero aproximada del set de datos, por medio de una selección con reposición de filas. Para que la selección sea reproducible, cada grupo debe modificar la `semilla` de selección (colocar cualquier número: 2345, 5432, 4512, etc.). **No debe repetir la semilla 1234**. La semilla seleccionada debe ser informada en el trabajo final, para su reproducibilidad.

Explore la tabla `datos` resultante antes de continuar (cantidad de filas y columnas, nombres y tipos de variables, valores faltantes `NA`). Elimine las filas sin datos utilizando `datos = na.omit(datos)`.

Preguntas guía

- Identifique las variables en estudio y clasifíquelas (tipo y escala de medición). Plantee las hipótesis nula (H_0) y alternativa (H_1) para evaluar si existe asociación entre el estado de enfermedad y la etapa de desarrollo. ¿Qué prueba estadística corresponde aplicar? Describa los supuestos del modelo.
- Calcule las frecuencias esperadas bajo la hipótesis de independencia y los grados de libertad. Ejecute la prueba estadística correspondiente y reporte el estadístico de prueba y el p-valor. Tome una decisión estadística con $\alpha = 0,05$.
- Interprete el resultado en el contexto del estudio de sarcomas. Identifique al menos una fuente de variabilidad no controlada o una limitación del análisis que requeriría datos adicionales, un ajuste del diseño o un análisis diferente.
- En el conjunto de datos importado, la variable disease indica si la muestra corresponde a un tumor (sarcoma) o a tejido sano (healthy). Si se deseara estimar la proporción poblacional de muestras que corresponden a sarcoma, ¿Qué método de estimación por intervalos corresponde aplicar para una proporción?
- Proponga el análisis de asociación entre un par cualquiera de las variables restantes.

Escenario 2: Selección del método adecuado de análisis (Producciones de Epistemología)

Deberá seleccionar 1 (uno) de los proyectos de investigación propuestos durante la cursada de Epistemología en 2026

https://drive.google.com/drive/folders/1ep2lHYbSeXyP8BIL651S7fpDTTDoHG_k?usp=drive_link.

Sobre ella, deberá resolver las preguntas guía.

Preguntas guía

- Identifique claramente la pregunta de investigación y los objetivos propuestos en el trabajo. A partir de ellos: Formule una pregunta estadística que se deba responder, y que esté relacionada con los objetivos de investigación. Identifique las variables aleatorias de estudio, especificando su tipo (cualitativa nominal/ordinal, cuantitativa discreta/continua) y su escala de medición. Defina cuál es el parámetro poblacional de interés (μ, Π, σ^2, $\mu_1 - \mu_2$, $\Pi_1 - \Pi_2$, β, etc.) y redacte explícitamente la hipótesis nula (H_0) y la hipótesis alternativa (H_1), en caso de corresponder.
- Indique el o los métodos estadísticos específicos que seleccionaría para responder a la pregunta planteada. ¿Cuál el propósito del análisis seleccionado: Describir, estimar un parámetro por intervalo, comparar grupos, evaluar asociación/independencia o modelar/predecir?Justifique su elección: Explique por qué este método es adecuado para su problema frente a otras alternativas posibles (por ejemplo, por qué usar una prueba de hipótesis en lugar de un intervalo de confianza, o por qué un análisis bivariado frente a uno univariado).
- Todo método estadístico descansa sobre un conjunto de supuestos implícitos. Enumere en forma de lista los supuestos teóricos requeridos para que el método elegido sea válido. Explique cuál sería la consecuencia sobre la validez de sus conclusiones (ej. incremento del Error Tipo I o pérdida de potencia) si alguno de estos supuestos no se llegara a cumplir en la práctica.
- Situándose en la etapa previa a la toma de datos: ¿Qué estrategias de muestreo considera que debería implementar para garantizar que se respeten los supuestos del método? (ej. aleatorización en la selección, asignación al azar de tratamientos, estructura de pares concordantes/ medidas repetidas, balance de grupos).
- Comente posibles limitaciones del diseño o del análisis, y señale qué potenciales sesgos o factores de confusión no controlados representan una limitación que deberá explicitarse en la discusión del trabajo.

Escenario 3: Parcelas de inventario forestal

En esta actividad hemos tomado las medidas de perímetro a la altura del pecho, altura de fuste (cuando DAP > 10cm) y posición sociológica. Este trabajo fue realizado anteriormente por la cohorte 2023 de estudiantes de biología.

https://drive.google.com/drive/folders/1lpt587lJ-q6Wj7qoVIin-pbzE9HGgcav?usp=drive_link

Por lo tanto, vamos a proponer las siguientes...

Preguntas guía

A partir del conjunto de datos proporcionado, genere dos nuevas columnas a cada tabla:

a. AT (Área Transversal): que corresponda a la superficie o sección de cada individuo calculada a partir del perímetro tomado.

b. HF (Altura del Fuste): que surja de combinar las dos medidas de altura (H1 y H2). Nota: Para el cálculo de HF, considere que H1 y H2 representan las pendientes expresadas en porcentaje tomadas desde una distancia de 10 metros. El cálculo es: HF = 10 * (H1 + H2) / 100.

Pueden usar el siguiente código *para los datos de cada parcela*, o bien modificar el set de datos original (pero ésto último no es una práctica recomendable, por lo que se lo realizaría únicamente a los fines de la evaluación):

```
library(dplyr)
# Previamente se debe haber importado los datos y almacenado con el nombre
'parcela'
parcela = parcela |>
  mutate(
    AT = perimetro^2 / (4 * pi),
    HF = 10 * (H1 + H2) / 100
  )
```

- ¿Existe un crecimiento en el área transversal media entre momentos? (Según cada tipo de parcela). Nota: llamaremos momento 1 a 2023 y momento 2 a 2026. Deben comparar parcelas del mismo tipo entre momentos (seleccione solo un tipo: parcela rectangular ó parcela circular).
- ¿Hay diferencias en las estimaciones de área transversal media según el tipo de parcela?
- ¿Hay diferencias en la composición de las categorías de posición sociológicas entre momentos?
- ¿Puede asumirse una relación o asociación entre el AT y la altura de fuste de tipo lineal?
- Aplique los métodos estadísticos necesarios para responderlas.